YANG Bin | LI Kaiyan

Master 2 Industrie de la Langue | Parcours professionnel | Semestre 1

UE : Projet Professionnel

Cahier des Charges

Évolution de l'appli EAF^2 en ligne dédiée au traitement de données langagières orales transcrites

Sommaire

1. Présentation des parties 3

a. Maître d'ouvrage 3

b. Maître d'œuvre 3

2. Présentation du projet 4

a. DylNet 4

b. L'appli EAF² 4

c. Étude du besoin 5

d. Objectifs 5

e. Délai 5

3. Descriptions des travaux proposés 6

a. Enrichissement fichiers 6

b. Analyse brute 6

c. Analyse organisée 6

d. Affichage des liaisons 7

f. Affichage des analyses statistiques 7

4. Spécificités techniques 9

a. Langage et outil 9

b. Base de données 9

c. Hébergement 10

5. Planning 11

a. Grandes dates 11

b. Gantt 12

c. DFD 15

6. Engagement de confidentialité 16

1. Présentation des parties

a. Maître d'ouvrage

i. Laboratoire de linguistique et didactique des langues étrangères et maternelles (LIDILEM, UGA)

ii. Commanditaires

Mme Aurélie Nardy, LIDILEM, aurelie.nardy@univ-grenoble-alpes.fr

Mme Isabelle Rousset, LIDILEM, isabelle.rousset@univ-grenoble-alpes.fr

M. Arnaud Bey, LITT&ARTS, arnaud.bey@univ-grenoble-alpes.fr

Mme Rachel Gaubil, LITT&ARTS et LIDILEM, rachel.gaubil@univ-grenoble-alpes.fr

M. Sylvain Hatier, LIDILEM, sylvain.hatier@univ-grenoble-alpes.fr

b. Maître d'œuvre

i. Coordonnés

Mme LI Kaiyan, M2 IDL, UGA
kaiyan.li@univ-grenoble-alpes.fr

M.YANG Bin, M2 IDL, UGA
bin.yang@univ-grenoble-alpes.fr

ii. Coordinateur du projet

M. Thomas Lebarbé lebarbet@univ-grenoble-alpes.fr

2. Présentation du projet

a. DylNet

Le projet DyLNet (Dynamiques langagières apprentissages linguistiques et sociabilité à l'école maternelle : apport des capteurs de proximité pour le recueil de données massives), coordonné par Aurélie Nardy et financé par l' Agence Nationale de la Recherche (ANR-16-CE28-0013), consiste à examiner comment les relations qu'entretiennent les enfants à l'école maternelle influencent le développement de leur langage oral (comment les enfants s'influencent les uns les autres et comment les adultes présents dans l'école ou les enseignants et ATSEM influencent le langage enfantin).

b. L'appli EAF^2

L'appli EAF^2 en ligne codée en python permettant de traiter automatiquement les fichiers de transcriptions a été développée. Cette appli autorise actuellement 6 fonctionnalités principales :

- **Enrichissement fichiers** : Lancer une analyse avec *Treetagger* en prenant un fichier eaf. comme entrée.
- **Négations :** Annoter les négations en "pas" ou d'autres mots négatifs.
- **Analyse brute et Analyse organisée :** Deux grands types d'extractions sont opérationnelles dans le logiciel. Le premier consiste à extraire, pour chaque forme langagière recherchée, tous les énoncés dans lesquels elle apparait en donnant pour chacun l'identifiant du locuteur ainsi que les informations contextuelles associées. Le second donne, pour chaque individu, le nombre d'occurrences de la forme langagière recherchée pour chacun des croisements d'informations contextuelles (140 combinaisons possibles).
- **Liaisons :** Annoter les contextes des liaisons facultatives en [LF].
- **Affichage des liaisons :** Faire des requêtes des liaisons par mot 1, mot 2 ou mot1+mot2.

- **Téléchargement :** Télécharger tous les fichiers produits dans les étapes précédentes et les supprimer après le téléchargement.

c. Étude du besoin

Les fonctionnalités de l'appli EAF² actuelle se réalisant globalement, il existe des inconvénients dans quelque unes, notamment celle d'affichage et analyse des liaisons et celle d'analyse organisée, ce qui embêtent les utilisateurs. Une évolution de cette appli est largement nécessaire pour que les liaisons facultatives soient analysées statistiquement**.**

d. Objectifs

Le produit que nous proposons est l'appli évoluée avec des fonctionnalités complétées et améliorées. Les travaux proposés de notre côté se composent de trois grands blocs (ci-dessous) et ils seront décrits précisément dans la partie "Description des travaux proposés"

- Développer la page de concordancier dédié au traitement des liaisons facultatives, afficher les analyses statistiques en calculant les fréquences et pourcentages des mot 1, mot 2 ou mot 1 + mot 2 dans les trois cas (LF1/LF3/LF1+LF3).
- Évoluer la fonctionnalité d'analyse organisée qui permettra de calculer des indicateurs langagiers comme la longueur moyenne des énoncés ou la diversité lexicale avec le choix de regroupement des énoncés selon différents critères.
- Implémenter l'étiqueteur morphosyntaxique Stanza (ajout d'une ligne dans le fichier de transcription au format .eaf).

e. Délai

Le délai de ce projet est de **2 mois**. Le rendu des projets, ainsi que des documentations et un manuel d'utilisation est au **21 février 2024**, sur la branche ***projetProIDL_2024-2025*** *de* l'EAF² GitLab UGA. La soutenance publique aura lieu le **28 février 2025**.

3. Descriptions des travaux proposés

a. Enrichissement fichiers

- Implémentation d'une analyse morphosyntaxique avec la librairie Stanza pour tous les tokens des énoncés et ajouter des résultats en une ligne dans le fichier eaf. version "_VB".

b. Analyse brute

- Sur la base de l'extraction brute actuelle, rajouter deux colonnes mot 1et mot 2

variable	variante	nom_fichier.e	periodes_pro	periodes_eco	num_class	id_dylnet	transcription	transcription_énoncé	mot1	mot2	activité	interlocuteur	situation
lf	[LF1]	24-20181011-	P1	rentree_A2	CL-24	ID-0133	et PRENOM e	et PRENOM	est	absente	En classe	Classe entière	Pas de situation langagière
lf	[LF1]	24-20181011-	P1	rentree_A2	CL-24	ID-0133	il étati pas [LF	il étati pas	pas	à	En classe	Classe entière	Pas de situation langagière
lf	[LF1]	24-20181011-	P1	rentree_A2	CL-24	ID-0133	tout le temps	et tous les	viennent	ici	Récréation	un ou plusieurs enfant(s)	Pas de situation langagière
lf	[LF1]	23-20181012-	P1	rentree_A2	CL-23	ID-0144	je recommenc	je	tout	au	En classe	un ou plusieurs enfant(s)	Pas de situation langagière
lf	[LF1]	23-20181012-	P1	rentree_A2	CL-23	ID-0144	il était [LF1] u	il était [LF1]	était	une	En classe	un ou plusieurs enfant(s)	Pas de situation langagière
lf	[LF1]	24-20181008-	P1	rentree_A2	CL-24	ID-0092	joyeux [LF1] a	joyeux [LF1]	joyeux	anniversaire	En classe	Auto	Récitation

c. Analyse organisée

- **Gestion du menu supérieur**

  L'idée est que lors du clic des checkboxes (regroupement contextuel, regroupement variable, regroupement par sexe du locuteur), le radiobutton "ajout de regroupements" doit être automatiquement choisi.

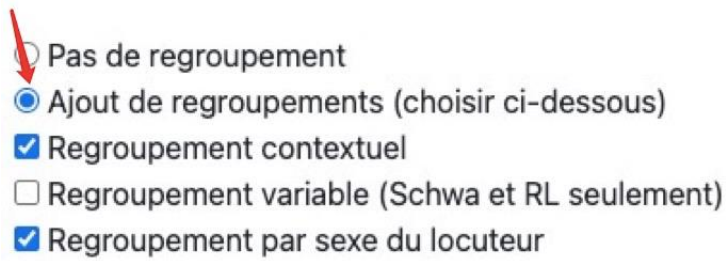

- **Ajustage du total dans les fichiers regroupés**

  L'idée est de rajuster le total de quelques mesures telles que LF1_global, LF3_global correspondant à leur valeur réelle dans les fichiers de sortie analysés avec des "*limites*"

d. Affichage des liaisons

- **La mise en forme de l'affichage des cas de liaisons recherchés**

  Par exemple, en choisissant "est" comme mot 1 et LF1 comme critère :

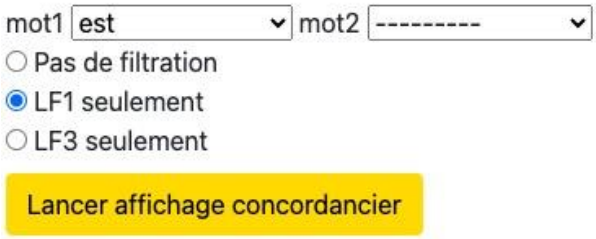

  Les liaisons trouvées seront affichées en tableau :

Fichier	Type de liaison	Contexte gauche	Liaison	Contexte droite
XXXXX	LF1	Il	***est ici***	.
XXXXX	LF1	Elle	***est à***	la recherche...
XXXXX	LF1	La petite fille	***est émue***	de...

- **Affichage des analyses statistiques**

L'idée est de faire une analyse sur les mots 1, mots 2 et mot1 + mot2 en calculant les fréquences et pourcentages par ordre décroissant dans les trois cas : LF1, LF3, LF1+LF3. Les résultats statistiques seront exportables dans un fichier .csv.

Mot 1			**Mot 2**			**Mot 1 + Mot 2**		
liste	fréquence	pourcentage	liste	fréquence	pourcentage	liste	fréquence	pourcentage
est	20	52%	à	12		est un	1	
sont	15	30%	ici	7		est une	2	
dans	8	5%	un	5		est à	3	
...	...	...	...	...	...	...	...	...

- **Création d'un bouton "Supprimer les fichiers analysés"**

L'idée est qu'une fois des fichiers analysés et les résultats exportés dans le "téléchargement", ce bouton permettra de supprimer tous les fichiers analysés.

4. Spécificités techniques

a. Langage et outil

Pour la réalisation des nouvelles fonctionnalités de l'appli EAF^2, nous utilisons les langages, bibliothèques et outils suivants :

- ***Python*** version 3.9
- Framework Web ***Flask*** version 3.1
- ***TreeTagger*** 3.2
- Module NLP ***Stanza*** Version 2.0.
- Modules Python :
    - ***Regex*** verison 2024.11.6
    - ***Treetaggerwrapper*** verison 2.3
    - ***Six*** verison 1.16
- ***GitLab UGA***
- ***Moodle UGA***

b. Base de données

Les données de l'appli EAF^2 sont organisées via un système de fichiers structuré. Ce système gère les informations suivantes :

- **Fichiers d'entrée** :

- Fichiers **.eaf** produits par le logiciel ELAN, contenant les transcriptions originales à analyser. Ces fichiers sont chargés dans le répertoire uploads.

- **Fichiers analysés et enrichis** :

- Fichiers **.eaf** enrichis, avec des annotations linguistiques ajoutées à chaque étape :
    - Version _VB : Résultat de l'analyse morphosyntaxique.
    - Version _VC : Annotation des négations.

- Version _VD : Annotation des liaisons facultatives.

- Résultats statistiques exportés au format **.csv** avec le séparateur "**;**" et le séparateur de décimales "." enregistrés dans le répertoire Sortie.

- **Fichiers de test** :

- Les fichiers de test, fournis pour valider les fonctionnalités, sont hébergés sur la plateforme ***Moodle UGA***. Ces fichiers, au format .eaf, sont utilisés pour simuler des cas réels d'analyse linguistique.

- **Métadonnées des fichiers** :

- Nom, type, taille et date de création/modification des fichiers sont suivis pour faciliter leur gestion.

c. Hébergement

L'appli EAF^2 n'est pas actuellement hébergée sur une plateforme externe. Elle fonctionne en mode local et peut être lancée via un serveur Flask accessible à l'adresse suivante :

http://localhost:5000

Le code source de l'application est versionné et géré sur la plateforme **GitLab**. Les mises à jour sont régulièrement poussées vers la **branche projetProIDL_2024-2025**, permettant un suivi des modifications et une gestion collaborative du projet.

Pour l'exécution locale, l'appli EAF^2 nécessite les prérequis suivants :

- Installation des dépendances via un environnement Python 3.9.
- Configuration d'un serveur local à l'aide de Flask.

5. Planning

a. Grandes dates

Date de début	Étape	Description
18/11/2024	Analyse des besoins	Identification des besoins et définition des spécifications.
28/11/2024	Rédaction	Finalisation du cahier des charges.
28/12/2024	Acceptation	Acceptation des cahiers des charges par les commanditaires.
06/01/2025	Développement	Réalisation des fonctionnalités prévues.
10/02/2025	Tests	Validation des fonctionnalités développées.
14/02/2025	Rédaction	Rédaction du manuel d'utilisation et des documentations.
21/02/2025	Livraison	Livraison du produit final.
28/02/2025	Soutenance	Présentation publique du projet.

Nous disposons de **7 semaines** pour assurer le bon fonctionnement du produit, respecter les délais de développement et fournir une documentation claire pour les utilisateurs.

b. Gantt

Définition de la tâche	Date de début	Date de fin	Jours	Responsable
Analyse des besoins	18/11/2024	27/11/2024	8	Y&L
Conception de la maquette	28/11/2024	04/12/2024	5	Y&L
Rédaction du cahier des charges	05/12/2024	20/12/2024	12	Y&L
Validation des cahiers des charges	21/12/2024	28/12/2024	8	Commanditaires
Installation d'environnement	21/12/2024	25/12/2024	5	Y&L
Téléchargement des données	25/12/2024	28/12/2024	4	Y&L
Développement :				
Enrichissement fichiers (Stanza intégration)	06/01/2025	12/01/2025	7	Y
Analyse brute	06/01/2025	10/01/2025	5	L
Analyse organisée (Gestion du menu supérieur)	13/01/2025	15/01/2025	3	Y
Analyse organisée (Ajustage du total)	11/01/2025	14/01/2025	4	L
Affichage des liaisons (Affichage des cas de liaisons recherchés)	15/01/2025	21/01/2025	7	L
Création d'un bouton suppression	16/01/2025	20/01/2025	5	Y

Affichage des liaisons (analyses statistiques)	22/01/2025	09/02/2025	19	Y&L
Tests	10/02/2025	13/02/2025	4	Y&L
Rédaction : Manuel d'utilisation et Documentation	14/02/2025	20/02/2025	7	Y&L
Livraison	21/02/2025	21/02/2025	1	Y&L
Soutenance publique	28/02/2025	28/02/2025	1	Y&L

DyLNet — Récemment sauvegardé 11:38

+ Nouveau | Ouvre. | Exporter | Modèle | Français

Samedi | Dimanche

	Coc	Nom de la tâche	Heure de début	Fin	Durée	Progrès a
1	/	DyLNet	2024-11-18	2025-02-28	103	30.10
2	1	Analyse des besoins	2024-11-18	2024-11-25	8	100
3	2	Conception de la maquette	2024-11-28	2024-12-02	5	100
4	3	Rédaction du cahier des charges	2024-12-05	2024-12-16	12	80
5	4	Validation des cahiers des chargescharge	2024-12-21	2024-12-28	8	0
6	5	Installation d'environnement	2024-12-21	2024-12-25	5	100
7	6	Téléchargement des données	2024-12-25	2024-12-28	4	100
8	7	Développement : Enrichissement fichiers	2025-01-06	2025-01-12	7	0
9	8	Développement : Analyse brute	2025-01-06	2025-01-10	5	0
10	9	Développement : Analyse organisée (Gest	2025-01-13	2025-01-15	3	0
11	10	Développement : Analyse organisée (Ajus	2025-01-11	2025-01-14	4	0
12	11	Développement : Affichage des liaisons (A	2025-01-15	2025-01-21	7	0
13	12	Développement : Création d'un bouton su	2025-01-16	2025-01-20	5	0
14	13	Développement : Affichage des liaisons (a	2025-01-22	2025-02-09	19	0
15	14	Tests	2025-02-10	2025-02-13	4	0
16	15	Rédaction: Manuel d'utilisation et Docume	2025-02-14	2025-02-20	7	0
17	16	Livraison	2025-02-21	2025-02-21	1	0
18	17	Soutenance publique	2025-02-28	2025-02-28	1	0

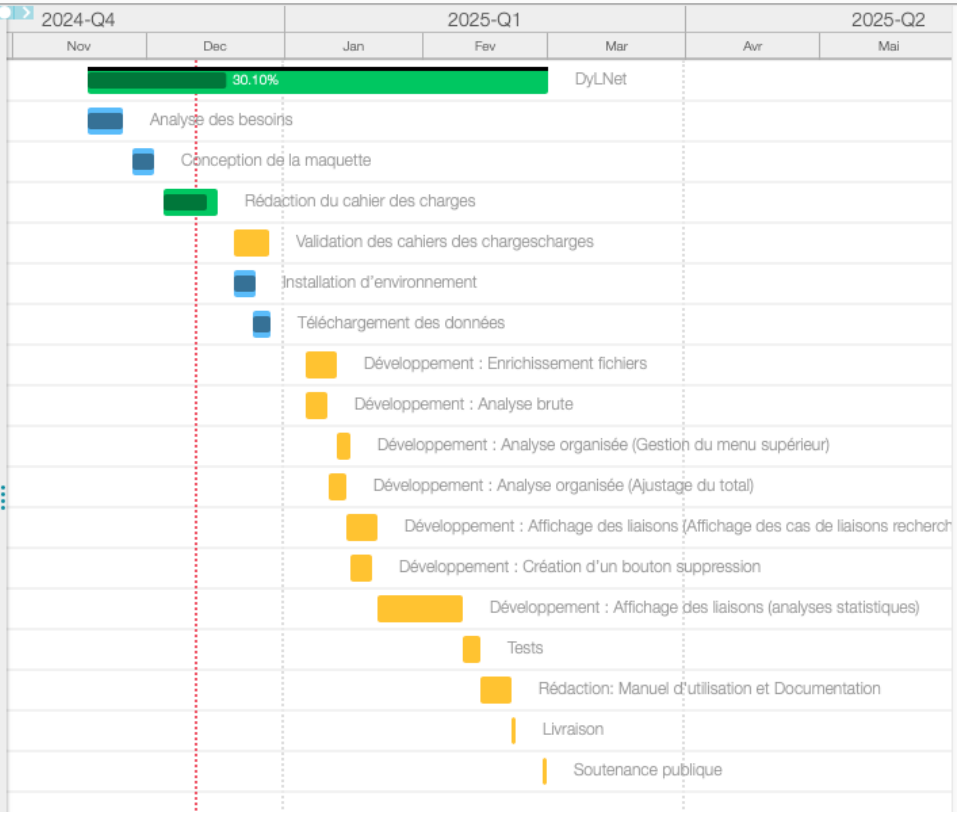

c. DFD

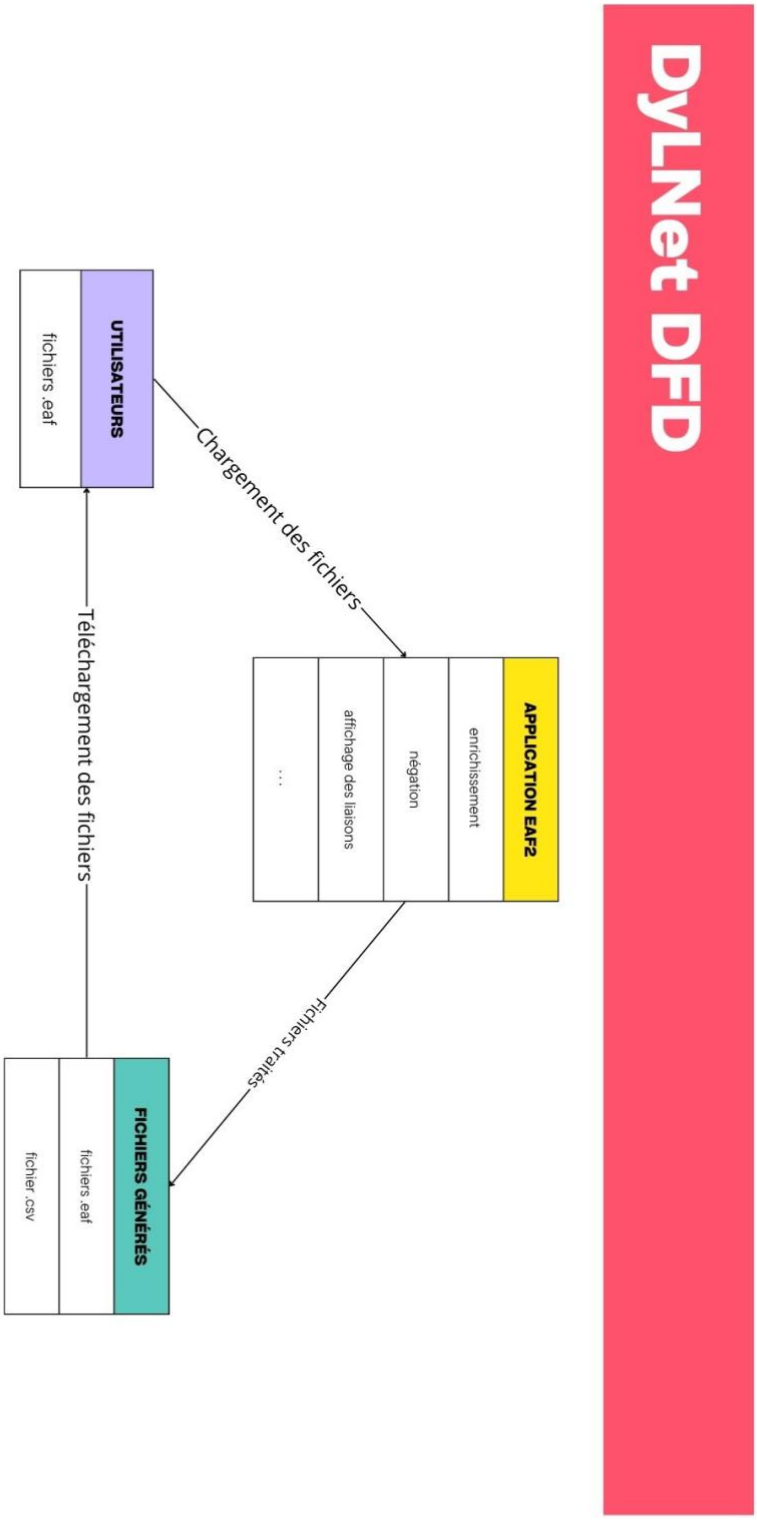
DyLNet DFD
APPLICATION EAF2
enrichissement
négation
affichage des liaisons
...
Chargement des fichiers
Fichiers traités
UTILISATEURS
fichiers .eaf
Téléchargement des fichiers
FICHIERS GÉNÉRÉS
fichiers .eaf
fichier .csv

6. Engagement de confidentialité

ENGAGEMENT DE CONFIDENTIALITÉ

Article 1 - Objet

Le présent engagement a pour objet de définir les conditions de confidentialité dans lesquelles M……., ci-après désigné par le BÉNÉFICIAIRE, est accueilli à dater du……. jusqu'au ……..
en qualité de ……..
au laboratoire de LIDILEM…….. (code de l'unité EA 609) ci-après désigné par le LABORATOIRE, dirigé par Laura Abou Haidar.

Article 2 - Programme et Responsable Scientifique

Pendant son séjour dans le LABORATOIRE, le BÉNÉFICIAIRE effectuera des travaux dans le cadre d'une étude intitulée : "DyLNet : Dynamiques langagières, apprentissages linguistiques et sociabilité à l'école maternelle : apport des capteurs de proximité pour le recueil de données massives", ci-après dénommée l'Etude.

Mme Aurélie Nardy, responsable scientifique de l'Étude, suivra les travaux du BÉNÉFICIAIRE au sein du LABORATOIRE.

Le BENEFICIAIRE est placé sous l'autorité du directeur du LABORATOIRE et doit se conformer au règlement intérieur dont il reconnaît avoir pris connaissance.

Article 3 – Obligation de réserve et d'obéissance hiérarchique

Le BENEFICIAIRE est soumis aux mêmes obligations que celles incombant à l'ensemble des agents publics, notamment celles d'obéissance hiérarchique et de réserve.

Article 4 – Confidentialité sur l'identité des personnes participant à l'étude

Le BENEFICIAIRE, lors du recueil, de la saisie et du traitement des données s'engage à ne pas dévoiler l'identité des individus participant à l'étude et à garder confidentielle toute information dont il aurait connaissance sur ces mêmes individus.

Article 5 - Propriété des Résultats

Le BÉNÉFICIAIRE reconnaît que les résultats de l'Etude ainsi que tous les résultats issus des travaux menés dans le cadre du LABORATOIRE (mise au point de produits, procédés de fabrication ou techniques), brevetables ou non, sont la propriété pleine et entière de l'UGA, qui disposera seule du droit de déposer les brevets correspondants, en son nom et à sa charge, dans les conditions prévues par le code de la propriété intellectuelle.

Cette clause s'applique également aux logiciels et bases de données créés dans le cadre de l'Etude.

En conséquence, le BENEFICIAIRE s'engage à ne pas exploiter pour son propre compte ou pour celui d'un tiers, sauf accord exprès de l'UGA, les résultats tels que définis ci-dessus.

Article 6 - Droit des inventeurs

L'UGA s'engage à ce que le nom du BENEFICIAIRE, s'il est considéré comme inventeur, soit mentionné dans les demandes de brevets en accord avec les dispositions légales en vigueur, à moins qu'il ne s'y oppose.

Le BENEFICIAIRE prêtera en toutes circonstances, son plus entier concours à l'UGA pour la demande et le maintien en vigueur desdits brevets ainsi que pour leur exploitation tant en France qu'à l'étranger.

Le BENEFICIAIRE s'interdit de déposer en son nom une demande de brevet dans quelque pays que ce soit, notamment aux Etats-Unis et s'engage à signer un accord de cession de droits en faveur de l'UGA.

Article 7 - Secret - Publications

Le Bénéficiaire ne pourra faire de publications ou de communications écrites ou orales relatives à l'Étude qu'après autorisation écrite de la responsable scientifique de l'Étude. Cette autorisation sera accordée dans le respect des accords que l'UGA a conclus avec ses contractants éventuels et dans la mesure où ces publications ne constitueraient pas une divulgation au sens du code de la propriété intellectuelle. Elle ne pourra être refusée que pour des raisons graves et dûment justifiées. En tout état de cause, le délai d'attente d'autorisation de publier ne pourra excéder trois (3) mois et au maximum dix-huit mois (18) dans le cas où les résultats seraient susceptibles de conduire au dépôt d'un brevet.

Les publications et communications du Bénéficiaire devront explicitement mentionner le nom du LABORATOIRE et de l'UGA.

Article 8

Sauf stipulations contraires, toutes ces dispositions demeurent valables à l'issue du séjour du BENEFICIAIRE dans le LABORATOIRE.

Fait à , le
en deux exemplaires originaux

Le **BENEFICIAIRE**
Signature sous la mention manuscrite "lu et approuvé"

Prénom NOM

Vu, le directeur du Laboratoire,

Prénom NOM
Laura Abou Haidar

Laura Abou Haidar
Directrice du laboratoire
LIDILEM

Vu, la responsable scientifique de l'Étude

Prénom NOM

Aurélie Nardy